

引用格式: 牛国臣, 梁向宇. 基于特征点提取的多传感器融合机坪建图方法[J]. 航空学报, 2024, 45(S1): 730806. NIU G C, LUAN X Y. A method for apron mapping based on feature point extraction and multi-sensor fusion [J]. Acta Aeronautica et Astronautica Sinica, 2024, 45(S1): 730806 (in Chinese). doi: 10.7527/S1000-6893.2024.30806

基于特征点提取的多传感器融合机坪建图方法

牛国臣^{1,2,*}, 梁向宇¹

1. 中国民航大学 机器人研究所, 天津 300300

2. 中国民航大学 民航智慧机场理论与系统重点实验室, 天津 300300

摘要: 机场停机坪环境具有场景范围较大、特征点稀疏的特征, 随机特征点数量的增加会导致建图失真和里程计漂移现象, 基于通过平滑和映射的紧耦合雷达惯性里程计算法(LIO-SAM)进行改进, 首先对激光雷达(LiDAR)和惯性测量单元(IMU)进行外参和内参标定, 将激光雷达点云格式转换为Velodyne格式, 并采用自适应特征点曲率计算, 以确保不同距离下特征点所计算曲率的准确性, 然后引入Scan-Context回环检测, 提高回环效率和建图精度, 最终生成高精度的停机坪环境点云地图, 通过实验平台采集园区道路和模拟停机坪两组数据集, 使用本文算法与主流的A-LOAM、LeGO-LOAM和LIO-SAM算法进行对比, 并利用GNSS数据作为轨迹真值。结果表明, 改进后的多传感器融合算法在停机坪环境下相较于原始LIO-SAM算法的绝对位姿误差均值降低了13.8%。相较于其他主流算法, 本文算法的绝对位姿误差均值最低, 提供了更高的建图精度, 有效降低了系统的累积误差, 生成的点云地图更好地还原了停机坪的真实场景。

关键词: 机场停机坪; 激光雷达; 惯性测量单元; 回环检测; 实验平台; 传感器融合

中图分类号: V351.392; V353; TN958.98 **文献标识码:** A **文章编号:** 1000-6893(2024)S1-730806-12

近年来, 随着中国科学技术的快速发展, 无人驾驶技术走进了人们日常生活中^[1], 应用领域也逐渐广泛, 例如机场内部无人作业车辆、封闭园区货物运输、卫生清洁车等, 自动驾驶技术的普及已经逐步成为未来发展的大趋势, 与此同时, 随着中国民航事业迅速发展, 智慧机场的建设也加快推进^[2], 无人化、少人化的趋势是未来智慧机场建设的重要目标, 针对机场停机坪环境下特种车辆较多、工作环境相对恶劣, 机场的人员安全和运行效率一直是机场最重视的问题, 无人驾驶技术引入机场将会使智慧机场的建设向前推进一大步, 在无人驾驶领域中, 即时定位与建图(Simultaneous Localization and Mapping, SLAM)是移动机器

人在未知环境中实现自主导航^[3]的一项基本要求, 国内外研究针对机场停机坪环境下三维激光雷达建图的团队极少, 本文提出一种多传感器融合的SLAM方法实现在机场停机坪环境下建立高精点云地图。

目前主流的SLAM方法有激光雷达SLAM^[4]和视觉SLAM^[5]这2种, 由于视觉传感器容易受到光照的影响^[6], 在室外正午和夜间的跨时间定位与地图构建其工作稳定性和鲁棒性都不如激光雷达, 基于激光雷达能在任何光照强度下正常工作^[7], 并且可以捕捉到环境中的细节, 有着较高的精度, 这在高精点云地图的构建过程中起到了重要的作用。

收稿日期: 2024-06-07; 退修日期: 2024-07-11; 录用日期: 2024-08-20; 网络出版时间: 2024-09-03 11:19

网络出版地址: <https://hkxb.buaa.edu.cn/CN/Y2024/V45/S1/730806>

基金项目: 国家自然科学基金(U2333205); 中央高校基本科研业务费(3122022PY10)

* 通信作者: E-mail: niu_guochen@139.com

对于三维激光雷达SLAM算法的应用与发展,很多学者对激光SLAM算法进行了深入研究:Zhang和Singh^[8]提出了三维激光雷达里程计建图算法(Lidar Odometry and Mapping, LOAM),在Kitti Odometry^[9]门类长期霸榜,LOAM算法主要提出了前端里程计和后端建图的思想,LOAM算法仅仅使用惯性测量单元(Inertial Measurement Unit, IMU)数据来消除激光雷达点云的运动畸变和在点云匹配前给出初始位姿,没有利用IMU数据进行优化,因此LOAM是一种松耦合的SLAM算法,并且没有引入闭环矫正,在点云地图构建过程中容易出现重影现象;Shan和Englot^[10]等在LOAM的基础上改进,提出了轻量化和地面优化的激光雷达里程计与建图算法(Lightweight and Ground-Optimized Lidar Odometry and Mapping on Variable Terrain, LeGO-LOAM),主要引入了点云分割的思想,首次将地面分割引入数据预处理,采用纯激光数据进行地面分割^[11],并且加入了闭环矫正,使算法较为轻量化,在保证精度的同时大大减少了计算量,但该方法所建的地图点云较为稀疏,难以通过点云配准实现精准的定位。Shan等^[12]同样基于LOAM提出了基于平滑和映射的紧耦合雷达惯性里程计算法(Tightly-coupled Lidar Inertial Odometry via Smoothing and Mapping, LIO-SAM),该算法是一种紧耦合的SLAM算法,主要采用因子图优化激光雷达(Light Detection and Ranging, LiDAR)里程计因子,IMU预积分因子,全球定位系统(Global Positioning System, GPS)因子和回环因子来得到实验平台全局一致性的位姿,并且开创性的使用了每一帧的点云和局部点云地图匹配,从而显著提升了帧图匹配的效率,保证了建图的实时性。

LIO-SAM算法使用了基于里程计的回环检测方案,主要通过关键帧和历史帧的距离远近判断是否构成回环^[13-14],Kim G和Kim A^[15]提出了Scan-Context算法,是一种基于扫描上下文的回环检测算法,将三维点云信息压缩为二维矩阵,利用了点云的最大高度信息。耿丽杰等^[16]提出一种将Scan-Context回环检测与点云配准NDT-ICP融合的建图方法,可以有效减少地图中的误

匹配,徐晓苏等^[17]提出了Scan-Context与激光雷达虹膜Lidar-Iris描述子^[18]结合的回环检测方法,主要利用Scan-Context描述子和KdTree搜索获取候选回环帧,并采用雷达虹膜描述子计算回环帧间的相似度得分,最后通过残差项加权的特征匹配获取位姿变换。

本文为了解决机场停机坪建图出现的特征点曲率计算准确度低,点云地图失真和里程计漂移现象。首先对传感器进行内参和外参的标定^[19],基于LIO-SAM算法改进,采用自适应曲率计算方法,解决了远距离特征点曲率计算精度问题,引入Scan-Context回环检测有效降低了里程计的累积误差,最后使用实验平台在实验园区和模拟停机坪采集2组带有回环的数据集,对比多种主流SLAM算法,来验证本文所提出的算法具有更高的建图精度,能将构建的停机坪点云地图更好的还原真实场景。

1 算法框架

本文提出的算法整体框架如图1所示。该算法框架主要包括前端特征点提取、扫描匹配、后端因子图优化和回环检测。首先要将激光雷达的点云数据格式转换为Velodyne点云数据格式,然后将LiDAR数据通过自适应曲率计算并且按照曲率由大到小依次排列进行特征点的提取,IMU的数据用来消除点云运动畸变,IMU的预积分通过与点云帧最优位姿融合作为迭代优化的初值求解位姿变换,实现了激光雷达里程计与IMU里程计的紧耦合。后端则采用因子图和回环检测来优化全局位姿。

2 传感器参数标定

针对机场停机坪大场景建图,单一激光雷达很难高效完成高精点云地图构建,由于激光雷达运动畸变无法快速补偿导致误差逐渐积累,所建点云地图容易出现失真和重影,因此多传感器融合的建图方法是机场停机坪大场景建图的发展趋势。

LiDAR和IMU所采集的数据都基于自身坐标系,由于这2种传感器实际安装位置和安装角度不同,所以需要求解其之间的相对位置和姿




图 1 算法整体框架

Fig. 1 Algorithm overall framework

态,通过LiDAR/IMU外参标定将2个传感器采集的数据转换到全局坐标系下,这样传感器采集的数据融合会更加准确,本文采用的外参标定工具为LiDAR_align,利用NLOpt库的非线性优化方法,让拼接后的点云最近邻点最小,并且需要用实验平台采集一个含有大量平移量和旋转量的数据集,通过多次标定迭代后,最终选取一个合适的优化量来作为LiDAR和IMU标定的结果。

本文采用的IMU内参标定工具为imu_utils,主要标定随机游走噪声和高斯白噪声,IMU内参标定过程需要在实验平台上录制一个将IMU静止至少2 h只有IMU话题的数据集,使用Ceres优化库通过艾伦方差分析法来确定高斯白噪声和随机游走噪声,IMU内参标定后会降低IMU数据的误差,提高IMU的测量精度和稳定性,从而进一步减小建图过程中出现的漂移现象、地图重影,提高定位精度。

3 自适应特征点曲率计算

本文所使用的机械式激光雷达型号为北科天绘R-Fans-16M,其是一个16线机械式激光雷达,激光束角度范围为 $(-15^{\circ} \sim +11^{\circ})$,上下扫描范围不对称,垂直分辨率为 $(1^{\circ} \sim 3^{\circ})$,水平视场角为 360° ,水平角分辨率为 0.18° ,最大测量距离为200 m,测量精度为 ± 2 cm,激光雷达扫描线垂直分布如图2所示。




图 2 R-Fans-16M扫描线分布

Fig. 2 Scanning line distribution of R-Fans-16M

机械式激光雷达主要以激光束扫描来获得点云信息,在激光扫描最大距离之内,点云会随着测量距离的增加而变得越来越稀疏,由于特征点云曲率计算是通过周围10个点云深度值和的平方来计算,当点云在地面上或者在距离激光雷达较远的地方时,特征点云曲率计算误差可以忽略不计,但是当激光束扫描到距离较远的建筑物上时,特征点云曲率的计算误差也随着测量距离的增加而逐渐变大,甚至会出现特征点的遗漏,如图3所示,当激光束扫描到建筑物的边缘点 e 时,可见在 e 点左边的5个点云都映射在建筑物上,而右侧只有一个点云映射在建筑物上,此时若采用左右各5个点云进行深度值之和的平方计算,则点云曲率计算的误差相对较大。

针对点云曲率计算精确度较低的问题,本文采用一种自适应点云曲率计算方法^[20],如图4所




图 3 点云在建筑物上映射分布
Fig. 3 Point cloud mapping distribution on building




图 4 自适应点云扫描分布
Fig. 4 Adaptive point cloud scanning distribution

示,首先判断激光束的角度,激光束的角度在 0° 以下扫描到的点云,依然使用传统的点云曲率计算方法,选取前后各5个点云进行深度值和的平方计算,激光束的角度在 0° 或者在 0° 以上获取的点云随着测量深度的增加参与曲率计算的点云数量逐渐减少,共分为远、中、近3个距离区间,对应的点云深度值为 R_f 、 R_m 、 R_n ,对应的激光束扫描范围为 θ_f 、 θ_m 、 θ_n ,距离较近时点云较为密集,可以按照传统方法选取前后各5个点云,当点云深度值超过中近距离的临界值时,则点云相对较为稀疏,此时可选取前后各3个点云来计算点云的曲率值,当点云深度值超过中远距离的临界值时,则点云非常稀疏,此时为了降低点云曲率计算的误差,选取前后各2个点云来参与点云曲率值的计算,当点云深度值过大或超过一定阈值则直接剔除,避免给点云曲率计算的精确性带

来干扰。

点云曲率计算公式为

$$C = \frac{1}{|S| \cdot \|r_i\|} \left\| \sum_{j \in S, j \neq i} (r_j - r_i) \right\| \quad (1)$$

式中: r_i 为第 i 个点云的深度值,单位为m; S 为同一激光扫描线上的连续点云集合,点云集合 S 在第 i 个点云两侧平均分布, $|S|$ 的值和 r_i 存在自适应的关系:

$$|S| \in [(10, r_i < 10), (6, r_i < 17), (4, r_i < 25), (2, r_i > 25)] \quad (2)$$

在图5所示的实际场景下,对比传统方法与加入自适应曲率计算后特征点提取的边缘特征点分布,绿色点云为提取的边缘特征点。图6展示了传统方法在距离激光雷达20 m处提取的边缘特征点分布。图7则展示了经过自适应曲率计算后提取的特征点分布,本文使用敏感度来衡量边缘点云提取的准确度,边缘点云提取越准确,敏感度越高。通过图6和图7中红色方框对比可知,经过自适应曲率计算的特征点云提取对边缘点提取的敏感度更高。



图 5 实际场景
Fig. 5 Real-world scene



图 6 传统特征点提取
Fig. 6 Traditional feature point extraction



图 7 自适应特征点提取
Fig. 7 Adaptive feature point extraction

4 计算因子图优化全局位姿

本文算法主要引入了因子图优化,通过将激光雷达里程计因子和IMU预积分因子、回环检测因子融入到因子图的框架中,实现了激光雷达数据和IMU数据的紧耦合,最终经过解算得到点云帧间的最优位姿。

4.1 IMU预积分因子

IMU可以使用较高的频率来测量机器人的线性加速度和角速度,可以满足机器人的快速运动变化,在整体的因子图中,IMU预积分因子部分的具体流程如图8所示。




图8 IMU预积分因子

Fig. 8 IMU preintegration factors

由图8中可以看出, X_i 表示机器人的状态节点,IMU预积分因子由2个关键帧之间的IMU测量积分得到,IMU主要是通过加速度计和陀螺仪来获得加速度和角速度,其测量公式为

$$\hat{\omega}(t) = \omega(t) + b_g(t) + n_g(t) \quad (3)$$

$$\hat{a}(t) = {}^W Q^T(t)(a(t) - g) + b_a(t) + n_a(t) \quad (4)$$

式中: $\hat{\omega}(t)$ 和 $\hat{a}(t)$ 分别是角速度和加速度的测量值; $\omega(t)$ 和 $a(t)$ 为角速度和加速度的真实值; $b_g(t)$ 和 $b_a(t)$ 分别是角速度和加速度的零偏,它们用随机游走模型来建模; $n_g(t)$ 和 $n_a(t)$ 是噪声,它们用高斯白噪声建模; g 为世界坐标系下的重力常矢量; ${}^W Q^T$ 为IMU坐标系到世界坐标系的转换矩阵的转置; I 和 W 分别代表了IMU坐标系和世界坐标系。

机器人在时刻 k 到 n 之间,对IMU的加速度数据和角速度数据进行积分,如式(5)~式(7),其中, ${}^W P_k$ 、 ${}^W V_k$ 和 ${}^W R_k$ 分别表示 k 时刻的位移、速度和旋转矩阵; ${}^W P_n$ 、 ${}^W V_n$ 和 ${}^W R_n$ 分别表示 n 时刻的位移、速度和旋转矩阵。

$${}^W P_n = {}^W P_k + \int_{t \in [k, n]} {}^W V_k dt + \frac{1}{2} \iint_{t \in [k, n]} [{}^W R_t(\hat{a}(t) - b_a(t) - n_a(t)) - g] dt^2 \quad (5)$$

$${}^W V_n = {}^W V_k + \int_{t \in [k, n]} [{}^W R_t(\hat{a}(t) - b_a(t) - n_a(t)) - g] dt \quad (6)$$

$${}^W R_n = {}^W R_k \exp \left[\int_{t \in [k, n]} (\hat{\omega}(t) - b_g(t) - n_g(t)) dt \right] \quad (7)$$

式中: ${}^W P_n$ 、 ${}^W V_n$ 和 ${}^W R_n$ 会受到 ${}^W P_k$ 、 ${}^W V_k$ 和 ${}^W R_k$ 的影响,意味着只要 k 时刻的位移、速度和旋转矩阵发生变化,就需要重新对IMU进行积分,为了避免重复积分,将积分时的坐标系从全局中标系转为IMU坐标系,这样IMU的测量值就与起始位置、速度和姿态无关。由IMU预积分得到时刻 k 与时刻 n 之间的状态增量为

$$\Delta P_{kn} = {}^W R_k \left({}^W P_n - {}^W P_k - {}^W V_k \Delta t - \frac{1}{2} g \Delta t^2 \right) \quad (8)$$

$$\Delta V_{kn} = {}^W R_k ({}^W V_n - {}^W V_k - g \Delta t) \quad (9)$$

$$\Delta R_{kn} = {}^W R_k {}^W R_n \quad (10)$$

式中: ΔP_{kn} 、 ΔV_{kn} 和 ΔR_{kn} 分别为位移、速度和旋转矩阵的增量; Δt 为时刻 k 到时刻 n 之间的时间差。由于IMU采样的数据是离散的,因此在算法中计算积分时,需要对连续时间的积分进行离散化,式(8)~式(10)是IMU预积分的离散形式。

4.2 激光里程计因子

LIO-SAM算法利用了关键帧的特征,提取第 i 个关键帧的特征 $F = \{F_i^e, F_i^p\}$,其中 F_i^e 表示边缘特征点; F_i^p 表示平面特征点,当有下一个关键帧 F_{i+1} 到来时,用之前的关键帧的特征集合 $\{F_{i-n}, F_{i-n+1}, F_i\}$ 构建局部地图 M_i ,激光里程计因子如图9所示。

构建得到的局部地图 M_i 公式为

$$M_i = \{M_i^e, M_i^p\} \quad (11)$$

$$M_i^e = {}^W F_i^e \cup {}^W F_{i-1}^e \cup \dots \cup {}^W F_{i-n}^e \quad (12)$$

$$M_i^p = {}^W F_i^p \cup {}^W F_{i-1}^p \cup \dots \cup {}^W F_{i-n}^p \quad (13)$$

式中: M_i^e 和 M_i^p 是局部边缘特征地图和局部平面特征地图在世界坐标系下的表示,分别是 ${}^W F_i^e$ 为 F_i^e 转换到全局坐标系下的边缘点, ${}^W F_i^p$ 为 F_i^p 转换到全局坐标系下的平面点。通过匹配 F_{i+1}^e 、 M_i^e 和




图 9 激光里程计因子

Fig. 9 Laser odometry factors

F_{i+1}^p, M_i^p , 建立点线和点面的约束关系。

4.3 回环检测

LIO-SAM 后端优化部分引入了回环检测, 在因子图中添加了回环因子如图 10 所示。

回环检测过程是先构建关键帧, 将关键帧的位姿存储, 以固定的频率进行回环检测, 然后通过处理最新的关键帧, 使用 KdTree 寻找历史关键帧中距离和时间满足条件的一个关键帧构成回环, 通过在历史帧的周围构建局部点云地图, 最后局部点云地图与当前关键帧通过 ICP 匹配来求解位姿变换。

本文在 LIO-SAM 算法的基础上引入了扫描上下文回环检测 (Scan-Context)^[21], 通过点云密度动态将点云进行分段, 以扫描上下文的方式检

测是否回到之前经过的场景, 算法主要是将激光雷达作为坐标系的原点, 并以激光雷达点云最远映射距离作为半径的圆沿径向划分为 N_r 个环区, 沿角度方向划分为 N_s 个扇区, 构成一个弯曲的网络。每个网格中点云的最大高度为网格值, 将三维的点云压缩成二维的图像, 并用 $N_r \times N_s$ 的二维矩阵来表示, 对矩阵的每一行进行计算得到该行的占据率作为 Ring Key 描述子, 描述子二维图像矩阵如图 11 所示。

网格内的点云最大高度用不同颜色代替, 当回环检测到历史帧时, 使用 ICP 匹配来求解位姿变换, 相比于 LIO-SAM 算法的半径搜索方法, 这显著提升了算法回环检测效率, 同时相比于原始 LIO-SAM 算法, 具有更高的精度和鲁棒性。




图 10 回环检测因子

Fig. 10 Loop closure detection factors




图 11 Scan-Context描述子矩阵

Fig. 11 Scan-Context descriptor matrix

5 实验分析

5.1 实验设备及实验场景

为验证本文算法在机场停机坪环境下建图的有效性和精确性,实验室现有的实验平台满足实验要求,使用该实验平台在实验园区和模拟停机坪环境下进行建图。使用的实验平台如图 12 所示,主要由长城欧拉 R1 电动汽车、北科天绘 R-Fans-16M 激光雷达、华测 CGI-410 组合导航系统、研华 ARK-3520 型号工控机配备 i7-6820HQ 处理器,工控机使用的操作系统为 Ubuntu18.04 LTS,运行内存为 32GB,ROS 版本为 Melodic。




图 12 实验平台

Fig. 12 Experimental platform

5.2 实验过程及实验结果

本次实验通过实验平台分别在实验园区道路和模拟停机坪环境下以 10 km/h 的速度采集 2 个带有回环的数据集,实验园区道路场景谷歌卫星地图如图 13 所示,实验平台的行驶轨迹使用黄色实线在谷歌卫星地图中标注。

在实验园区道路场景下使用 A-LOAM、LeGO-LOAM、LIO-SAM 以及本文的算法进行里程计轨迹对比,并以 GNSS 数据作为轨迹真值,在实验园区道路场景下轨迹对比如图 14 所示,由于②点处的实际场景几何特征较为简单,



图 13 实验园区场景谷歌卫星地图

Fig. 13 Google satellite map in experiment scenario

提取的特征点较为单调,实际场景如图 15 所示, LeGO-LOAM 算法里程计出现了较为严重的漂移,而 A-LOAM 算法由于没有回环检测,其绝对位姿误差也相对较大,所构建的点云地图也出现了较为严重的失真。本文所提出的算法绝对位姿误差的误差均值较低,其轨迹绝对位姿误差和相对位姿误差对比结果如表 1 和表 2 所示,结合表 1 中绝对位姿误差和表 2 中相对位姿误差数据对比可知,本文所提出的算法相较于原始 LIO-SAM 算法绝对位姿误差均值降低了 10.05%,相较于 A-LOAM 和 LeGO-LOAM 绝对位姿误差均值也是最低,但是相对位姿误差并未有显著降低。

模拟停机坪环境相对于实验园区道路环境更加复杂,模拟停机坪内有较多机场特种车辆和特种维修设备,模拟停机坪环境谷歌地图如图 16 所示,其中,部分飞机位置由于谷歌地图的更新频率问题有略微变动。在模拟停机坪环境下,驾驶实验平台并且与飞机保持一定安全距离的情况下采集带有回环的数据集,停机坪数据集采集场景如图 17 所示。

在模拟停机坪环境下使用 A-LOAM、LeGO-LOAM、LIO-SAM 以及本文算法进行里程计轨迹对比,以 GNSS 作为真实轨迹,算法对比结果如图 18 所示,通过局部里程计轨迹放大展示了本文算法相较于 A-LOAM、LeGO-LOAM、LIO-SAM 等主流算法更接近真实轨迹,其具体对比结果如表 3 绝对位姿误差和表 4 相对位姿误差所




图 14 实验园区道路场景轨迹比较

Fig. 14 Comparison of trajectories in campus road scenarios



图 15 ②号点实际场景

Fig. 15 Actual scene at Point 2



图 16 模拟停机坪谷歌卫星地图

Fig. 16 Simulated airport apron google satellite map

表 1 实验园区道路场景绝对位姿误差比较

Table 1 Comparison of absolute pose errors in campus road scenarios

采用算法	最大值/m	最小值/m	误差均值/m
A-LOAM	3.688	0.331	1.302
LeGO-LOAM	5.503	0.906	2.815
LIO-SAM	2.912	0.309	0.905
Ours	1.885	0.107	0.814

表 2 实验园区道路场景相对位姿误差比较

Table 2 Comparison of relative pose errors in campus road scenarios

采用算法	最大值/m	最小值/m	误差均值/m
A-LOAM	0.713	0.000 3	0.197
LeGO-LOAM	2.079	0.000 7	0.983
LIO-SAM	1.032	0.000 4	0.514
Ours	1.011	0.000 4	0.486



图 17 模拟停机坪数据集采集场景

Fig. 17 Simulated airport apron dataset collection scenario

示,在模拟停机坪环境下,本文所提出的算法相较于原始LIO-SAM算法绝对位姿误差均值降低了13.8%。

在模拟停机坪环境下,实验平台的运动轨迹包含多次拐弯,本文算法并没有因为拐弯次数较多而产生失真和漂移现象。模拟停机坪建图效




图 18 模拟停机坪场景轨迹比较
Fig. 18 Comparison of simulated apron trajectories

表 3 模拟停机坪场景绝对位姿误差比较
Table 3 Comparison of absolute pose errors in simulated apron scenarios

采用算法	最大值/m	最小值/m	误差均值/m
A-LOAM	3.159	0.063	0.963
LeGO-LOAM	2.584	0.031	0.894
LIO-SAM	1.365	0.219	0.623
Ours	1.148	0.118	0.537

表 4 模拟停机坪场景相对位姿误差比较
Table 4 Comparison of relative pose errors in simulated apron scenarios

采用算法	最大值/m	最小值/m	误差均值/m
A-LOAM	1.223	0.001 2	0.328
LeGO-LOAM	1.982	0.001 0	0.435
LIO-SAM	1.305	0.000 6	0.358
Ours	1.254	0.000 7	0.319

果如图 19 所示,通过对点云地图的局部放大,可以看出本文算法所建立的点云地图更好的还原了真实场景,局部点云地图如图 20 所示,其在全局点云地图中的位置由黄色线框在图 19 中标注,在局部点云地图可以看出飞机蒙皮上的点云和地面点云有着较为明显的分界线。

A-LOAM、LeGO-LOAM、LIO-SAM 和本文算法所构建的局部点云地图如图 21 所示,从以上几种主流 SLAM 算法的局部点云地图可以看出 A-LOAM 和 LeGO-LOAM 算法所构建的点云地图出现较为严重的失真现象,导致飞机的机头位置和机翼位置出现较多重影,LIO-SAM 算




图 19 模拟停机坪全局点云地图

Fig. 19 Global point cloud map of simulated apron




图 20 模拟停机坪局部点云地图

Fig. 20 Local point cloud map of simulated apron




图 21 模拟停机坪局部点云地图对比

Fig. 21 Comparison of local point cloud maps of simulated apron

法所构建的点云地图失真现象相对较少,但用于后续的高精度定位工作仍然存在较大风险,本文算法构建的点云地图相较于以上几种主流SLAM算法构建的点云地图失真现象最少,能更好的还原真实场景。

6 结 论

本文针对机场停机坪环境中建图和定位需求,首先配置了16线激光雷达、IMU、GPS等多

传感器融合的无人驾驶平台,考虑到机场停机坪环境较大、特征点较为稀疏,在LIO-SAM算法的基础上使用自适应点云曲率计算提高了特征点提取的准确性,并且对LiDAR和IMU进行外参和内参标定来提高IMU的测量精度和稳定性,引入Scan-Context进一步减小建图过程中出现的漂移现象和地图失真现象。最后通过园区道路场景和模拟停机坪场景采集两组数据集进行测试,本文算法在2种场景下相较于A-LOAM、LeGO-LOAM和LIO-SAM在里程计精度和点云地图平滑性上均有较大提升。在后期的研究中考考虑如何在恶劣环境下实现停机坪的高精度建图工作,以及在停机坪地面有积水的情况下如何消除点云地图地面点以下反射到飞机蒙皮上的稀疏点云。

参 考 文 献

- [1] CHAI J H, DONG M L, SUN P, et al. 工业相机自热引起像点漂移模型与补偿方法[J]. Infrared and Laser Engineering, 2021, 50(6): 20200494.
- [2] 王冠岭,李辉,赵生捷,等. 基于“四型机场”建设目标的智慧飞行区建设研究文献综述[J]. 人工智能, 2022, (4): 8-16. WANG G L, LI H, ZHAO S J, et al. Literature review on the construction of intelligent flight zones based on the “Four-Type Airport” construction goals[J]. Artificial Intelligence, 2022, (4): 8-16 (in Chinese).
- [3] 仇新,张禹,苏晓明. 基于启发式算法的移动机器人SLAM[J]. 中国惯性技术学报, 2018, 26(1): 45-50. ZHANG X, ZHANG Y, SU X M. Simultaneous localization and mapping of mobile robot based on heuristic algorithm[J]. Journal of Chinese Inertial Technology, 2018, 26(1): 45-50 (in Chinese).
- [4] ALSADIK B, KARAM S. The simultaneous localization and mapping (SLAM)-An overview[J]. Journal of Applied Science and Technology Trends, 2021, 2(4): 120-131.
- [5] TAKETOMI T, UCHIYAMA H, IKEDA S. Visual SLAM algorithms: A survey from 2010 to 2016[J]. IPSJ Transactions on Computer Vision and Applications, 2017, 9(1): 16.
- [6] 周治国,曹江微,邸顺帆. 3D激光雷达SLAM算法综述[J]. 仪器仪表学报, 2021, 41(9): 13-27. ZHOU Z G, CAO J W, DI S F. Overview of 3D lidar SLAM algorithms[J]. Chinese Journal of Scientific Instrument, 2021, 41(9): 13-27 (in Chinese).
- [7] WANG H, WANG C, CHEN C L, et al. F-LOAM:

- Fast LiDAR odometry and mapping [C] //2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). Piscataway: IEEE Press, 2021: 4390-4396.
- [8] ZHANG J, SINGH S. LOAM: Lidar odometry and mapping in real-time[J]. Robotics: Science and Systems. 2014, 2(9): 1-9..
- [9] GEIGER A, LENZ P, STILLER C, et al. Vision meets robotics: the KITTI dataset[J]. The International Journal of Robotics Research, 2013, 32(11): 1231-1237.
- [10] SHAN T X, ENGLT B. LeGO-LOAM: Lightweight and ground-optimized lidar odometry and mapping on variable terrain[C]//2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). Piscataway: IEEE Press, 2018: 4758-4765.
- [11] XU X B, ZHANG L, YANG J, et al. A review of multi-sensor fusion SLAM systems based on 3D LIDAR[J]. Remote Sensing, 2022, 14(12): 2835.
- [12] SHAN T X, ENGLT B, MEYERS D, et al. LIO-SAM: Tightly-coupled lidar inertial odometry via smoothing and mapping[C]//2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). Piscataway: IEEE Press, 2020: 5135-5142.
- [13] STEDER B, RUHNKE M, GRZONKA S, et al. Place recognition in 3D scans using a combination of bag of words and point feature based relative pose estimation [C]//2011 IEEE/RSJ International Conference on Intelligent Robots and Systems. Piscataway: IEEE Press, 2011: 1249-1255.
- [14] HIMSTEDT M, FROST J, HELLBACH S, et al. Large scale place recognition in 2D LIDAR scans using Geometrical Landmark Relations [C]//2014 IEEE/RSJ International Conference on Intelligent Robots and Systems. Piscataway: IEEE Press, 2014: 5030-5035.
- [15] KIM G, KIM A. Scan context: Egocentric spatial descriptor for place recognition within 3D point cloud map [C]//2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). Piscataway: IEEE Press, 2018: 4802-4809.
- [16] 耿丽杰, 顾健, 别晓婷, 等. 基于 Scan Context 与 NDT-ICP 相融合的果园建图方法研究[J]. 中国农机化学报, 2022, 43(7): 44-50.
GENG L J, GU J, BIE X T, et al. Research on orchard SLAM method based on Scan Context and NDT-ICP fusion[J]. Journal of Chinese Agricultural Mechanization, 2022, 43(7): 44-50 (in Chinese).
- [17] 徐晓苏, 李诺, 姚逸卿. 基于快速闭环检测的室外环境下激光雷达 SLAM 算法[J]. 中国惯性技术学报, 2022, 30(6): 716-722.
XU X S, LI N, YAO Y Q. Lidar SLAM algorithm in outdoor environment based on fast loop detection [J]. Journal of Chinese Inertial Technology, 2022, 30(6): 716-722 (in Chinese).
- [18] WANG Y, SUN Z Z, XU C Z, et al. LiDAR iris for loop-closure detection [C]//2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). Piscataway: IEEE Press, 2020: 5769-5775.
- [19] 杜秀铎, 崔丽珍, 张清宇, 等. 基于 LIO-SAM 框架矿山环境下的点云地图构建[J]. 内蒙古科技大学学报, 2022, 41(4): 367-371.
DU X D, CUI L Z, ZHANG Q Y, et al. Point cloud map construction in mining environment based on LIO-SAM framework [J]. Journal of Inner Mongolia University of Science and Technology, 2022, 41(4): 367-371 (in Chinese).
- [20] 杨书涛, 郁汉琪, 戴红卫, 等. 基于特征提取改进的 LeGO-LOAM 方法[J]. 南京工程学院学报(自然科学版), 2023, 21(3): 21-26.
YANG S T, YU H Q, DAI H W, et al. Improved LeGO-LOAM method based on feature extraction [J]. Journal of Nanjing Institute of Technology (Natural Science Edition), 2023, 21(3): 21-26 (in Chinese).
- [21] 汪湘川, 张辉, 陈波, 等. 基于扫描上下文优化的紧耦合激光 SLAM 方法[J/OL]. 控制与决策: 1-9 [2024-04-02].
WANG X C, ZHANG H, CHEN B, et al. A tightly-coupled LiDAR SLAM method based on scan context optimization [J/OL]. Control and Decision: 1-9 [2024-04-02] (in Chinese).

A method for apron mapping based on feature point extraction and multi-sensor fusion

NIU Guochen^{1,2,*}, LUAN Xiangyu¹

1. Civil Aviation University of China, Robotics Institute, Tianjin 300300, China

2. Key Laboratory of Smart Airport Theory and System, Civil Aviation University of China, Tianjin 300300, China

Abstract: The airport apron environment features a large scene range and sparse feature points. Increased random feature points can lead to mapping distortion and odometer drift. This paper presents improvements based on the tightly-coupled Lidar Inertial Odometry via Smoothing and Mapping (LIO-SAM) method. Firstly, the external and internal parameter calibration of Light Detection and Ranging (LiDAR) and Inertial Measurement Unit (IMU) is conducted, the LiDAR point cloud format is converted into the Velodyne format, and adaptive feature point curvature calculation is used to obtain accurate curvature at various distances. Then, Scan-Context loop detection is introduced to enhance loop efficiency and mapping accuracy, so as to generate a high-precision apron environment point cloud map. Two datasets, park roads and a simulated apron, are collected using the experimental platform for comparison. The proposed algorithm is evaluated against the A-LOAM, LeGO-LOAM, and LIO-SAM algorithms, using GNSS data as trajectory ground truth. Results show that the improved multi-sensor fusion algorithm reduces the mean absolute pose error by 13.8% compared to the original LIO-SAM algorithm in apron environments. The proposed algorithm also has the lowest mean absolute pose error among mainstream algorithms, providing higher mapping accuracy, reducing cumulative error, and better restoring the real scene of the apron.

Keywords: airport apron; LiDAR; IMU; loop detection; experimental platform; sensor fusion

Received: 2024-06-07; **Revised:** 2024-07-11; **Accepted:** 2024-08-20; **Published online:** 2024-09-03 11:19

URL: <https://hkxb.buaa.edu.cn/CN/Y2024/V45/IS1/730806>

Foundation items: National Natural Science Foundation of China (U2333205); Fundamental Research Funds for the Central Universities (3122022PY10)

* **Corresponding author.** E-mail: niu_guochen@139.com