

文章编号: 1671-251X(2025)09-0142-09

DOI: 10.13272/j.issn.1671-251x.2025070095

# 面向矿井环境的激光雷达-惯性-视觉 紧耦合 SLAM 算法

卢艳军, 吕宛桐, 张晓东

(沈阳航空航天大学 自动化学院, 辽宁 沈阳 110136)

**摘要:** 矿井环境中非结构化地形、光照条件差及特征重复等条件导致单一传感器的同时定位与地图构建 (SLAM) 精度不足, 多传感器数据紧耦合融合可在一定程度上提升精度, 但仍存在计算量大、光照突变适应性差等问题。针对上述问题, 以快速紧耦合稀疏直接激光雷达-惯性-视觉里程计 (FAST-LIVO) 算法为基础进行改进, 提出一种面向矿井环境的激光雷达-惯性-视觉紧耦合 SLAM 算法。在多传感器数据紧耦合融合部分, 采用 LK (Lucas-Kanade) 光流法代替原有稀疏直接法, 利用光流法追踪稳定特征点并构建视觉重投影误差, 同时利用随机样本一致 (RANSAC) 算法剔除离群点以保留高质量视觉约束; 结合惯性测量单元 (IMU) 先验估计与激光雷达点到平面残差, 通过迭代误差状态卡尔曼滤波器实现多传感器数据紧耦合融合, 输出高精度位姿。在地图构建部分, 采用增量式 k-d 树 (ikd-Tree) 动态管理点云以构建激光雷达局部地图; 通过网格筛选与 Shi-Tomas 得分计算提取视觉特征点, 并采用数组管理实时移除视场外特征点以构建视觉局部地图; 通过将激光雷达点云投影至对应图像提取 RGB 颜色信息生成彩色点云帧, 再依据优化位姿拼接彩色点云帧以构建彩色点云地图。基于 Gazebo 仿真平台的测试结果表明, 相比 FAST-LIVO 算法, 所提算法的绝对轨迹误差 (ATE) 和相对位姿误差 (RPE) 均降低了 20% 以上, 且巷道侧壁、内部料堆轮廓、地面等特征更清晰。在公开数据集 M2DGR 上的测试结果表明, 所提算法的定位精度较 LEGO-LOAM, FAST-LIO 及 FAST-LIVO 算法有所提升, 且在转弯处无明显漂移, 轨迹稳定性更优, 且所提算法处理数据的平均时间缩短。在走廊模拟环境的测试结果表明, 所提算法对空间结构的还原更清晰, 线条、轮廓等细节更精准, 噪点抑制效果更佳, 能更准确地反映真实环境布局。

**关键词:** 机器人定位; 同时定位与地图构建; SLAM; 激光雷达-惯性-视觉; 多传感器数据紧耦合融合; 光流法; 卡尔曼滤波

中图分类号: TD67

文献标志码: A

LiDAR-inertial-vision tightly-coupled SLAM algorithm for mining environments

LU Yanjun, LYU Wantong, ZHANG Xiaodong

(School of Automation, Shenyang Aerospace University, Shenyang 110136, China)

**Abstract:** In underground mining environments, unstructured terrains, poor lighting conditions, and repetitive features lead to insufficient accuracy in single-sensor simultaneous localization and mapping (SLAM). Although tight coupling fusion of multi-sensor data can improve accuracy to some extent, challenges remain, including high computational load and poor adaptability to sudden illumination changes. To address these issues, an improved LiDAR-inertial-visual tightly-coupled SLAM algorithm was proposed based on the Fast Tightly-Coupled Sparse-Direct LiDAR-Inertial-Visual Odometry (FAST-LIVO) algorithm. For multi-sensor tight coupling fusion, the Lucas-Kanade (LK) optical flow method was adopted to replace the original sparse direct method, tracking stable feature points and constructing a visual reprojection error. Meanwhile, the random sample

收稿日期: 2025-07-23; 修回日期: 2025-09-19; 责任编辑: 盛男。

基金项目: 国家重点研发计划项目 (2022YFC2903805)。

作者简介: 卢艳军 (1968—), 女, 辽宁义县人, 教授, 硕士研究生导师, 博士, 主要研究方向为自动检测技术和无人机自主飞行控制技术, E-mail: sylyj2004@126.com。

引用格式: 卢艳军, 吕宛桐, 张晓东. 面向矿井环境的激光雷达-惯性-视觉紧耦合 SLAM 算法[J]. 工矿自动化, 2025, 51(9): 142-149, 166.

LU Yanjun, LYU Wantong, ZHANG Xiaodong. LiDAR-inertial-vision tightly-coupled SLAM algorithm for mining environments[J]. Journal of Mine Automation, 2025, 51(9): 142-149, 166.



扫码移动阅读

consensus (RANSAC) algorithm was applied to eliminate outliers and retain high-quality visual constraints. By combining Inertial Measurement Unit (IMU) prior estimation with LiDAR point-to-plane residuals, the iterative error-state Kalman filter was employed to achieve tight coupling fusion of multi-sensor data, outputting high-precision pose estimates. For map construction, an incremental  $k$ -d tree (ikd-Tree) was employed to dynamically manage point clouds for building the LiDAR local map. Visual feature points were extracted through grid filtering and Shi-Tomasi score calculation, while an array was utilized to manage and dynamically remove features outside the field of view, constructing the visual local map. The LiDAR point clouds were projected onto corresponding images to extract RGB color information, generating colored point cloud frames. These frames were then stitched based on optimized poses to construct a colored point cloud map. Experimental results on the Gazebo simulation platform demonstrated that, compared to the FAST-LIVO algorithm, the proposed method reduced both absolute trajectory error (ATE) and relative pose error (RPE) by over 20%, with clearer features such as tunnel sidewalls, internal pile contours, and ground surfaces. Tests on the public M2DGR dataset showed that the proposed algorithm achieved higher localization accuracy than LEGO-LOAM, FAST-LIO, and FAST-LIVO, exhibited no significant drift at turns, and maintained superior trajectory stability. Additionally, the average data processing time of the proposed method was reduced. Test results in a long corridor simulation environment demonstrate that the proposed algorithm achieves clearer reconstruction of spatial structures, more accurate details such as lines and contours, better noise suppression, and more precise reflection of the actual environmental layout.

**Key words:** robot localization; simultaneous localization and mapping; SLAM; LiDAR-inertial-visual; tightly-coupled multi-sensor data fusion; optical flow method; Kalman filter

## 0 引言

随着人类对矿产资源的持续开发,地表资源逐渐枯竭,矿产资源开发重心逐步转向地下,深部开采、智能开采、绿色开采已成为我国地下矿山开采的核心发展方向<sup>[1]</sup>。由于矿井环境封闭,全球定位系统(Global Positioning System, GPS)、实时动态载波相位差分(Real-Time Kinematic, RTK)等传统定位技术无法适用<sup>[2]</sup>。同时定位与地图构建(Simultaneous Localization and Mapping, SLAM)技术可使移动机器人在未知环境中实时定位,同时构建环境地图<sup>[3]</sup>。但矿井特有的复杂地形、狭窄巷道、光照条件差及特征重复等问题<sup>[4]</sup>,使单一传感器的SLAM精度不足,机器人的前端位姿估计退化甚至失效<sup>[5]</sup>,例如:激光雷达在狭长巷道中易出现位姿估计退化;视觉传感器在低照度、弱纹理区域特征提取困难;惯性测量单元(Inertial Measurement Unit, IMU)存在累计误差随时间漂移现象。因此,需要通过多传感器融合方式提升算法定位和建图精度<sup>[6]</sup>。

多传感器融合方式主要有松耦合和紧耦合。松耦合是将各传感器分割成独立运行的模块,然后在机器人估计姿态约束的情况下进行融合;紧耦合是在状态估计阶段直接融合多传感器的原始数据,将不同传感器的观测建模到同一目标函数中<sup>[7]</sup>。紧耦合因能在低层次上融合多传感器数据、优化时序同步问题,相比松耦合更能提升算法的抗干扰能力,更

适合矿井环境。在多传感器数据紧耦合融合研究中,激光雷达与IMU的组合较为常用。文献[8]将IMU预积分因子、激光里程计因子、GPS因子和闭环因子共同纳入一个因子图中进行联合优化,取得了较好的建图效果,但并未考虑矿井中对称巷道退化对SLAM结果的影响,且需要后端优化,计算量较大。文献[9]提出了一种快速紧耦合激光惯性里程计算法,采用直接法处理原始点云,将新扫描的点直接注册到逐步构建的点云地图中,通过最小化点到平面的距离优化位姿。这种方法虽省去特征提取的过程,减少了计算量,但牺牲了一定精度,更适合小尺度场景。随着技术的持续演进,激光雷达-IMU-相机融合的SLAM方案已成为研究热点,其通过引入视觉信息进一步增强了对复杂场景的适应性。文献[10]首次实现了激光雷达、IMU与视觉的紧耦合融合,提升了估计精度和对剧烈运动的鲁棒性。但其闭环检测模块针对结构化环境设计,难以应对矿井巷道重复纹理场景,易产生累计误差。文献[11]提出了基于平滑与映射的激光雷达-视觉-惯性里程计紧耦合系统,该系统包含视觉惯性系统(Visual-Inertial System, VIS)和激光惯性系统(LiDAR-Inertial System, LIS)2个子系统,通过因子图优化紧密耦合,虽然在视觉或激光退化场景中仍能保持稳定的性能,但其计算开销较大,与矿井移动机器人的资源受限特性不匹配。文献[12]提出了快速紧耦合稀疏直接激光雷达-惯性-视觉里程计(Fast and Tightly-Coupled Sparse-Direct LiDAR-Inertial-Visual Odometry, FAST-

LIVO), 结合稀疏直接法将图像与原始点配准的优势, 以较低的计算代价实现了精确位姿估计。但其在矿井环境中仍存在局限性, 传统稀疏直接法进行视觉对齐时依赖纹理与稳定光照, 而且直接作用于位姿, 在矿井光照突变场景容易出现视觉对齐失败, 导致位姿估计漂移甚至丢失。

针对矿井环境的特殊性, 本文提出一种激光雷达-惯性-视觉紧耦合 SLAM 算法。该算法以 FAST-LIVO 算法为基础进行改进, 采用光流法代替原有的稀疏直接法, 稳定跟踪特征点实现图像对齐; 利用随机样本一致(Random Sample Consensus, RANSAC)算法剔除离群点, 保留高质量视觉约束以更新位姿, 增强算法对矿井场景光照突变的抵抗能力; 通过多传感器数据紧耦合融合, 实现矿井环境下的高精度位姿估计与地图构建。

## 1 算法框架

面向矿井环境的激光雷达-惯性-视觉紧耦合 SLAM 算法框架如图 1 所示。在多传感器数据紧耦合融合部分, 对 IMU 数据进行前向传播, 对移动机器人的状态进行实时预测生成先验估计, 并对激光雷达点云进行畸变补偿。同时, 利用光流法在相机获得的图像中追踪视觉地图中的特征点, 并使用 RANSAC 算法对离群点加以剔除。接着, 分别计算激光雷达点到平面残差、视觉重投影误差, 并将其与 IMU 先验估计相结合, 通过迭代误差状态卡尔曼滤波器完成多传感器数据的紧耦合融合, 并输出移动机器人位姿。在地图构建部分, 将去畸变后的点云注册到激光雷达局部地图, 针对每个新的激光雷达点云, 将其投影至对应的图像中, 提取各投影点的 RGB 颜色以形成带颜色的点云, 进而得到全局的彩色点云地图。同时, 从彩色点云地图中提取视觉显著的点作为视觉特征, 添加到视觉局部地图, 用于存储位于当前相机视场内的视觉特征点。

## 2 多传感器数据紧耦合融合

### 2.1 IMU 前向传播

在移动机器人的状态估计中, 对 IMU 数据进行前向传播是关键环节。本文借鉴文献[9]中的 IMU 测量与状态估计机制, 利用 IMU 输出的高频加速度和角速度数据, 基于离散化的运动模型实现机器人状态的实时预测<sup>[13]</sup>, 为后续与激光雷达数据及视觉数据的紧耦合融合提供可靠的先验估计。设  $k$  时刻机器人的真实状态为  $a_k$ , 通过 IMU 前向传播得到的预测状态为  $\hat{a}_k$ , 预测状态与真实状态之间的误差协方差的预测值为  $\hat{p}_k$ ,  $\hat{p}_k$  与  $\hat{a}_k$  共同构成先验估计:

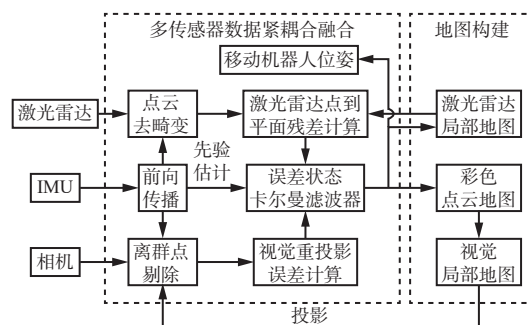


图 1 激光雷达-惯性-视觉紧耦合 SLAM 算法框架

Fig. 1 LiDAR-inertial-vision tight-coupled SLAM algorithm framework

$$a_k \ominus \hat{a}_k \sim N(0, \hat{p}_k) \quad (1)$$

式中  $\ominus$  为流形上的减法算子, 用于量化真实状态  $a_k$  与预测状态  $\hat{a}_k$  的误差。

### 2.2 激光雷达点到平面残差计算

激光雷达对环境进行扫描以获取点云数据。由于移动机器人在实际作业中的非线性运动会导致激光点云产生畸变, 所以当接收到激光雷达扫描数据时, 需首先通过反向传播机制补偿扫描过程中的运动畸变。具体地, 依据 IMU 提供的运动信息, 将扫描时段内不同时刻采集的激光点统一校正至扫描结束时刻的空间位置, 并转换到激光雷达坐标系下, 以消除运动畸变, 为后续点云地图配准提供无畸变测量输入。

对于经过去畸变处理的激光雷达点, 在将其配准至地图时, 假设每个点均位于地图内某一相邻平面上, 若利用真实状态  $a_k$  (即姿态) 将激光雷达点从激光雷达坐标系转换至全局坐标系, 此时激光雷达点到平面残差理论上应为 0, 即

$$0 = r_1(a_k, {}^L P_j) = \mu_j^T ({}^G T_{U_k} {}^U T_L {}^L P_j - q_j) \quad (2)$$

式中:  $r_1$  为激光雷达点到平面残差;  ${}^L P_j$  为第  $j$  个激光雷达点在激光雷达坐标系  $L$  下的坐标;  $\mu_j$ ,  $q_j$  分别为地图中与第  $j$  个激光雷达点相匹配的平面法向量和中心点;  ${}^G T_{U_k}$  为全局坐标系  $G$  到  $k$  时刻 IMU 坐标系  $U$  的位姿变换矩阵;  ${}^U T_L$  为激光雷达坐标系到 IMU 坐标系的外参变换矩阵。

$r_1$  一方面用于约束激光雷达当前帧与局部地图之间的位姿关系, 通过最小化残差精准修正机器人位姿, 另一方面为地图更新提供有效的环境约束, 保障建图过程中点云配准的准确性。

### 2.3 视觉重投影误差计算

视觉重投影误差是指同一个特征点在当前图像帧中的实际观测位置与其根据当前相机位姿估计投影得到的预测位置之间的差值。本文采用光流法实现帧间特征点的跟踪与数据关联, 为视觉重投影误差计算提供可靠的观测数据<sup>[14]</sup>。

光流法通过提取角点、边缘点等稳定特征点,即使在低质量图像中也能快速且准确地追踪特征点的位移轨迹<sup>[14]</sup>。这一特性使其适用于井下光照条件差、粉尘干扰严重的视觉环境中,为移动机器人的定位与建图提供了可靠的视觉运动约束。其中,LK(Lucas-Kanade)光流法<sup>[15]</sup>基于灰度不变性、小运动、邻域一致性3个基本假设,通过分析图像序列中局部窗口的亮度变化,计算角点、边缘等特征点的运动速度(即光流),通过提取运动物体附近光流变化的方向,实现对运动目标运动状态的估计。

LK光流法的核心基础是灰度不变性假设,即假设某一特征点在连续图像帧中的灰度值保持一致。由于特征点是由像素点集合构成,所以通过像素点的光流结果进一步分析特征点所在区域的光流情况。设第 $t$ 帧图像中像素点 $(x,y)$ 的灰度值为 $I(x,y,t)$ ,在第 $t+\Delta t$ 帧中,该像素点运动到 $(x+\Delta x,y+\Delta y)$ 处,灰度值为 $I(x+\Delta x,y+\Delta y,t+\Delta t)$ ,根据灰度不变性假设,建立如下光流方程:

$$I(x,y,t) = I(x+\Delta x,y+\Delta y,t+\Delta t) \quad (3)$$

对式(3)进行一阶泰勒展开:

$$I(x+\Delta x,y+\Delta y,t+\Delta t) \approx I(x,y,t) + \frac{\partial I(x,y,t)}{\partial x} \Delta x + \frac{\partial I(x,y,t)}{\partial y} \Delta y + \frac{\partial I(x,y,t)}{\partial t} \Delta t \quad (4)$$

将式(3)代入式(4)后除以 $\Delta t$ ,可得

$$\frac{\partial I(x,y,t)}{\partial x} \frac{\Delta x}{\Delta t} + \frac{\partial I(x,y,t)}{\partial y} \frac{\Delta y}{\Delta t} + \frac{\partial I(x,y,t)}{\partial t} = 0 \quad (5)$$

定义 $I_x = \frac{\partial I(x,y,t)}{\partial x}$ ,  $I_y = \frac{\partial I(x,y,t)}{\partial y}$ ,  $I_t = \frac{\partial I(x,y,t)}{\partial t}$ ,  $u = \lim_{\Delta t \rightarrow 0} \frac{\Delta x}{\Delta t}$ ,  $v = \lim_{\Delta t \rightarrow 0} \frac{\Delta y}{\Delta t}$ ,得到光流约束方程:

$$I_x u + I_y v + I_t = 0 \quad (6)$$

式中: $I_x, I_y$ 分别为像素点在水平、垂直方向上的空间梯度; $I_t$ 为像素点的时间梯度; $u, v$ 分别为像素点在水平、垂直方向上的运动速度。

光流约束方程包含2个未知数,无法直接求解。依据LK光流法的邻域一致性假设,设以像素点 $(x,y)$ 为中心的邻域窗口包含 $N$ 个像素点,窗口中每个像素点 $(x_n, y_n)$  ( $n=1, 2, \dots, N$ )均满足光流约束方程,由此建立方程组:

$$\begin{bmatrix} I_{x_1} & I_{y_1} \\ I_{x_2} & I_{y_2} \\ \vdots & \vdots \\ I_{x_N} & I_{y_N} \end{bmatrix} \begin{bmatrix} u \\ v \end{bmatrix} = \begin{bmatrix} -I_{t_1} \\ -I_{t_2} \\ \vdots \\ -I_{t_N} \end{bmatrix} \quad (7)$$

将式(7)记为 $\mathbf{A}\mathbf{d} = \mathbf{b}$ ,  $\mathbf{A} = \begin{bmatrix} I_{x_1} & I_{x_2} & \dots & I_{x_N} \\ I_{y_1} & I_{y_2} & \dots & I_{y_N} \end{bmatrix}^T$ ,

$$\mathbf{d} = [u \quad v]^T, \mathbf{b} = [-I_{t_1} \quad -I_{t_2} \quad \dots \quad -I_{t_N}]^T。$$

利用最小二乘法求解方程组,得到光流 $\mathbf{d}$ 的最优解。

$$\mathbf{d} = (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \mathbf{b} \quad (8)$$

通过上述步骤计算出当前帧中特征点的光流后,对特征点在后续图像帧中进行跟踪。通过不断重复上述步骤,即在每一帧图像上计算特征点的光流,实现对运动目标的连续跟踪。

设第 $t$ 帧图像中第 $i$ 个特征点在像素坐标系中的位置 $\mathbf{Q}_{t,i} = [x_{t,i} \quad y_{t,i}]^T$  ( $x_{t,i}, y_{t,i}$ 分别为第 $t$ 帧图像中第 $i$ 个特征点在水平、垂直方向的像素点坐标),基于光流法的运动向量 $\mathbf{F}_{t,i} = [\Delta x_{t,i} \quad \Delta y_{t,i}]^T$  ( $\Delta x_{t,i}, \Delta y_{t,i}$ 分别为从第 $t$ 帧到第 $t+\Delta t$ 帧图像中第 $i$ 个特征点在水平、垂直方向的像素点坐标偏移量),可预测第 $i$ 个特征点在第 $t+\Delta t$ 帧图像中的位置:

$$\hat{\mathbf{Q}}_{t+\Delta t,i} = \mathbf{Q}_{t,i} + \mathbf{F}_{t,i} \quad (9)$$

将预测位置即光流跟踪的位置 $\hat{\mathbf{Q}}_{t+\Delta t,i}$ 与第 $i$ 个特征点在当前图像中的实际观测位置 $\mathbf{Q}_{t+\Delta t,i}^c = [x_{t+\Delta t,i}^c \quad y_{t+\Delta t,i}^c]^T$  ( $x_{t+\Delta t,i}^c, y_{t+\Delta t,i}^c$ 分别为第 $t+\Delta t$ 帧图像中第 $i$ 个特征点在水平、垂直方向的实际像素点坐标)进行对比,二者的差异构成视觉重投影误差:

$$\mathbf{r}_c = \mathbf{Q}_{t+\Delta t,i}^c - \hat{\mathbf{Q}}_{t+\Delta t,i} \quad (10)$$

通过不断调整相机位姿,使视觉重投影误差最小化,实现对相机姿态的优化,保证后续视觉特征地图构建的准确性。

## 2.4 误差状态卡尔曼滤波器

为实现精准的位姿估计与地图优化,融合IMU、雷达及视觉多源观测信息,构建误差状态卡尔曼滤波器<sup>[16]</sup>。将IMU前向传播得到的先验估计与激光雷达点到平面残差和视觉重投影误差结合,得到最大后验概率估计目标函数:

$$\min_{\mathbf{a}_k \in \mathcal{M}} \left( \|\mathbf{a}_k - \hat{\mathbf{a}}_k\|_{\Sigma_k}^2 + \sum_{j=1}^{m_l} \left\| \mathbf{r}_l(\mathbf{a}_k, {}^L P_j) \right\|_{\Sigma_l}^2 \right) + \sum_{i=1}^{m_c} \left\| \mathbf{r}_c(\mathbf{a}_k, {}^G P_i) \right\|_{\Sigma_c}^2 \quad (11)$$

式中: $\mathcal{M}$ 为真实状态 $\mathbf{a}_k$ 所在流形; $m_l$ 和 $m_c$ 分别为激光雷达点数量和视觉有效特征点数量; $\Sigma_l$ 和 $\Sigma_c$ 分别为激光雷达和视觉的噪声协方差矩阵; ${}^G P_i$ 为第 $i$ 个特征点在全局坐标系下的坐标。

当接收到激光雷达扫描时,式(11)仅将激光雷达点到平面残差 $\mathbf{r}_l$ 与IMU数据融合(即 $m_c = 0$ );当接收到图像信息时,式(11)仅将视觉重投影误差 $\mathbf{r}_c$ 与IMU数据融合(即 $m_l = 0$ )。接着通过高斯-牛顿方法迭代求解误差状态,最终输出移动机器人位姿,为后续建图提供可靠依据。

### 3 地图构建

#### 3.1 激光雷达局部地图

激光雷达局部地图由三维激光点云构成,其数据组织采用增量式 k-d 树<sup>[17]</sup>(Incremental k-dimensional Tree, ikd-Tree)结构。ikd-Tree 作为一种动态点云管理工具,不仅提供点云的查询、插入及删除等基础操作接口,还在内部以给定分辨率对点云图进行采样,通过实时监视树结构并重建相应的子树来动态平衡树结构。当接收新的激光雷达扫描数据时,首先基于预测位姿对扫描点进行坐标变换,随后通过 ikd-Tree 查询获得对应区域的最近邻点;然后将原始点云与 IMU 数据融合,利用点云配准算法求解精确位姿;最后将经位姿变换后的点云投影至全局坐标系,并完成向 ikd-Tree 的增量式插入,实现激光雷达局部地图的动态更新。

#### 3.2 视觉局部地图

视觉局部地图用于存储和管理位于当前相机视场内的视觉特征点,由于特征点数量较少,采用简单的数组进行管理。针对每一帧新的激光雷达点云,将其投影到对应的图像中,并将图像划分成  $40 \times 40$  的网格,用较大的网格对像素点进行初步筛选。在每个网格内,通过计算所有投影点的 Shi-Tomasi 得分以表示视觉特征的显著程度<sup>[18]</sup>,并选择得分最高的点作为视觉特征点加入视觉地图,为下一帧图像的视觉观测构建提供基础。此外,为控制视觉特征点总量,实时移除局部地图中已脱离当前图像视场的特征点,实现地图的动态精简。

#### 3.3 彩色点云地图

彩色点云地图通过为激光雷达点云赋予图像颜色信息,进一步提升点云的环境表征能力。在每次卡尔曼滤波更新完成后,得到更准确的移动机器人位姿估计。将最新激光雷达点云帧中的点逐一投影到对应图像中,提取各投影点所在像素的 RGB 颜色信息,形成具有颜色属性的点云帧。随着算法的持续运行,更多的彩色点云帧依据优化后的位姿拼接在一起,最终构建出全局的彩色点云地图。

### 4 算法性能测试

#### 4.1 仿真环境下算法性能测试

在 Gazebo 仿真平台中搭建一个长 100 m、宽 5 m、高 3 m 的矿井环境仿真模型,包括巷道侧壁和料堆。在巷道部署 1 个轮式机器人模型,搭载 mid360 激光雷达、6 轴 IMU 传感器及 D435i 相机,用于采集仿真环境数据。仿真场景如图 2 所示。启动机器人操作系统(Robot Operation System, ROS)核

心节点和各传感器驱动节点,控制设备以 0.5 m/s 的速度在巷道中移动,在仿真环境中采集数据。




图 2 仿真场景

Fig. 2 Simulation scenario

为验证本文所提激光雷达-惯性-视觉紧耦合 SLAM 算法的准确性与鲁棒性,利用 EVO 轨迹评估工具,对比 FAST-LIVO 算法与本文算法估计的轨迹,如图 3 所示。可看出本文算法估计轨迹相对真实值的偏移更小,整体形状基本一致,路径近乎重合,表明本文算法抑制了巷道起伏引起的 IMU 漂移与激光雷达特征退化,平面运动估计更准确。




图 3 FAST-LIVO 算法改进前后估计轨迹对比

Fig. 3 Comparison of estimated trajectories before and after improvement of FAST-LIVO algorithm

FAST-LIVO 算法与本文算法的绝对轨迹误差(Absolute Trajectory Error, ATE)和相对位姿误差(Relative Pose Error, RPE)见表 1、表 2。

表 1 FAST-LIVO 算法改进前后的 ATE

Table 1 ATE before and after improvement of FAST-LIVO algorithm

指标	FAST-LIVO 算法	本文算法	相对变化率/%
均方根误差	0.389 966	0.288 740	-25.96
平均误差	0.320 983	0.237 690	-25.95
误差中值	0.309 548	0.163 159	-47.29
标准差	0.221 458	0.163 934	-25.98



表 2 FAST-LIVO 算法改进前后的 RPE  
Table 2 RPE before and after improvement of FAST-LIVO algorithm

指标	FAST-LIVO算法	本文算法	相对变化率/%
均方根误差	0.066 593	0.047 334	-28.92
平均误差	0.052 873	0.035 070	-33.67
误差中值	0.042 021	0.026 658	-36.56
标准差	0.040 485	0.031 791	-21.47

从表 1、表 2 可看出,FAST-LIVO 算法的均方根误差、平均误差、误差中值及标准差等指标数值相对较高,且误差波动幅度大;而本文算法的各项误差指标不仅数值更低,且波动小。表明本文算法在复杂矿井环境中的定位精度提升,同时具备更优的稳定性与鲁棒性。

采用 FAST-LIVO 算法和本文算法分别对仿真环境进行建图,效果对比如图 4 所示。可看出 FAST-LIVO 算法构建的地图特征模糊,几何边缘不明显;本文算法构建的地图中巷道侧壁、内部料堆轮廓、地面等主要特征能够清晰呈现,结构规整,几何形态可辨,建图清晰度明显提升。



图 4 FAST-LIVO 算法改进前后在仿真环境中的建图效果对比  
Fig. 4 Comparison of mapping performance in simulation environment before and after improvement of FAST-LIVO algorithm

4.2 公开数据集下算法性能测试

为验证本文算法在复杂场景下的准确性与鲁棒性,选取适用于多模态与多传感器机器人 SLAM 的公开数据集 M2DGR<sup>[19]</sup>进行测试。该数据集中 hall\_04 序列为室内走廊场景,该场景具有特征单一的特点,与矿井环境相似,对算法的定位精度和稳定性提出了较高挑战,适用于评估算法在特征稀疏场景下的性能。将本文算法与应用广泛的 LeGO-LOAM 算法<sup>[20]</sup>、FAST-LIO 算法<sup>[9]</sup>及 FAST-LIVO 算法估计的轨迹进行对比,如图 5 所示,轨迹误差见表 3。

从图 5、表 3 可看出,LEGO-LOAM 算法估计轨

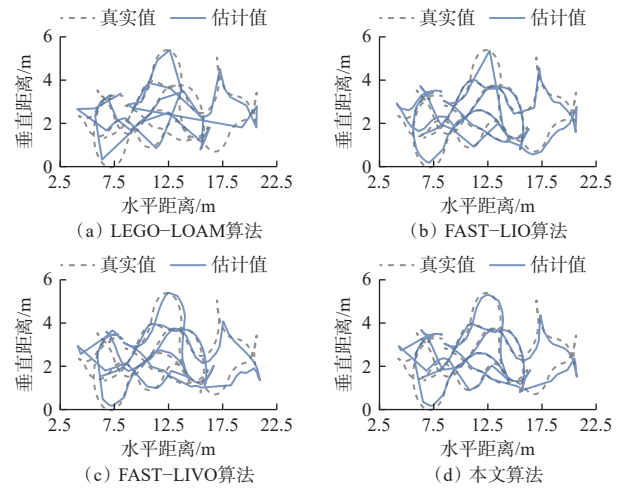


图 5 不同算法估计的轨迹对比  
Fig. 5 Comparison of trajectories estimated by different algorithms  
表 3 不同算法轨迹误差  
Table 3 Trajectory errors of different algorithms

指标	LEGO-LOAM算法	FAST-LIO算法	FAST-LIVO算法	本文算法
ATE	最大误差	1.617 0	1.865 8	1.567 4
	平均误差	1.053 0	0.902 0	<b>0.851 3</b>
	最小误差	0.179 6	0.155 1	0.163 1
	均方根误差	1.099 9	0.965 1	<b>0.927 5</b>
	标准差	<b>0.318 1</b>	0.343 3	0.368 1
RPE	最大误差	11.693 6	5.595 1	<b>2.886 9</b>
	平均误差	1.939 5	<b>0.170 7</b>	0.362 1
	最小误差	0.013 3	0.003 5	<b>0.000 8</b>
	均方根误差	2.636 1	0.695 9	<b>0.613 2</b>
	标准差	1.785 3	0.588 1	<b>0.494 9</b>

迹出现明显偏移,误差较大;FAST-LIO 算法和 FAST-LIVO 算法性能虽优于 LEGO-LOAM 算法,但整体精度不如本文算法;本文算法均方根误差最小,估计轨迹与真实值最为接近,尤其在转弯处表现最稳,无大尺度漂移。

为评估本文算法在计算效率方面的表现,测试本文算法与 FAST-LIVO 算法处理每一帧数据的平均时间,结果如图 6 所示。




图 6 FAST-LIVO 算法改进前后数据处理时间对比  
Fig. 6 Comparison of data processing time before and after improvement of FAST-LIVO algorithm

从图 6 可看出, 本文算法处理每一帧数据的平均时间为 41.09 ms, FAST-LIVO 算法处理每一帧数据的平均时间为 49.46 ms, 本文算法较 FAST-LIVO 算法耗时减少约 17%, 且本文算法在帧索引大时耗时曲线整体更平稳, 波动幅度相对较小, 说明本文算法在处理不同帧数据时更具有稳定性。

#### 4.3 模拟环境下算法性能测试

为验证本文算法的建图精度, 利用长走廊场景模拟矿井环境进行测试, 如图 7 所示。该走廊具备与矿井巷道相似的狭长空间结构、相对封闭的环境特性, 且存在一定的光照变化与局部结构重复区域, 能够模拟矿井环境特征。




图 7 模拟环境

Fig. 7 Simulation environment

测试平台采用 COBOT-D100-P 移动机器人和 NUC11PAHi7 机载主控计算机, 如图 8 所示。机器人配备 mid360 激光雷达 (内置 6 轴 IMU) 及 D435i 相机, 激光雷达、IMU、相机的采样频率分别为 10 Hz, 32 kHz, 30 Hz。在 ROS 中, 可直接调用 ROS 驱动包, 通过串口通信方式实现对移动机器人的控制并获取环境数据。




图 8 测试平台

Fig. 8 Test platform

在采集数据前, 需进行相机内参标定及激光雷达-相机外参标定。先采用张正友标定法标定相机内参, 将打印的棋盘格图案贴于平面作为标定物, 如图 9(a)所示, 使用相机从不同角度和距离拍摄 15 张照片, 打开 Matlab 的 Camera Calibrator 标定工具箱并导入照片, 工具箱自动识别角点, 点击标定即可求解内参矩阵 (包含焦距、主点坐标、畸变系数等)。标

定完成后输出的结果显示, 相机内参的重投影误差为 0.117 2, 远小于认定标定精度 (0.5)。完成相机内参标定后, 利用 livox\_camera\_calib 标定工具<sup>[21]</sup>进行激光雷达-相机外参标定, 如图 9(b)所示, 获取激光雷达与相机的相对位置关系。具体流程: 首先在合适的标定场景中运行激光雷达与相机采集数据; 然后从采集的数据中提取出激光雷达点云数据和相机图像数据, 按标定工具要求格式整理后导入; 最后运行标定程序, 在 Rviz 可视化环境中, 标定工具自动提取点云中的线特征和图像中的对应线特征, 通过对齐线特征实现激光雷达和相机的外参计算, 从而确定激光雷达坐标系与相机坐标系之间的相对位置和姿态关系, 完成外参标定。




(a) 相机内参标定界面 (b) 激光雷达-相机外参标定界面

图 9 标定界面

Fig. 9 Calibration interface

完成标定后, 控制设备在长走廊运动, 采集模拟环境数据, 并分别使用 FAST-LIVO 算法和本文算法对环境进行建图, 如图 10 所示。可看出在模拟环境下, FAST-LIVO 算法所建地图在场景呈现上存在一定的细节缺失与噪点, 对复杂结构的刻画精度有限; 本文算法构建的地图对空间结构还原更清晰, 线条、轮廓等细节更精准, 噪点抑制效果更佳, 能更准确地反映真实环境布局。



(a) FAST-LIVO算法

(b) 本文算法

图 10 FAST-LIVO 算法改进前后在模拟环境中的建图效果对比  
Fig. 10 Comparison of mapping performance in simulation environment before and after improvement of FAST-LIVO algorithm

## 5 结论

1) 在 FAST-LIVO 算法的基础上, 提出了一种激光雷达-惯性-视觉紧耦合 SLAM 算法。采用光流法替代原有的稀疏直接法进行视觉观测, 提升了特

征点追踪在恶劣光照和弱纹理条件下的鲁棒性; 通过构建视觉重投影误差, 并结合激光雷达点到面残差与 IMU 先验估计, 利用迭代误差状态卡尔曼滤波器实现了多传感器数据的紧耦合融合。

2) 在 Gazebo 仿真场景中, 所提算法的 ATE 与 RPE 各项指标较 FAST-LIVO 算法降低了 20% 以上, 其中 ATE 误差中值降低了 47.29%, RPE 误差中值降低了 36.56%, 且巷道侧壁、内部料堆轮廓、地面等特征呈现更清晰。

3) 在公开数据集 M2DGR 中, 所提算法的 ATE 均方根误差为 0.927 5 m, 较 LEGO-LOAM 算法、FAST-LIO 算法、FAST-LIVO 算法分别降低了 15.67%, 3.90%, 10.96%; RPE 均方根误差为 0.609 2 m, 优于对比算法, 尤其在转弯处无明显漂移, 轨迹稳定性更优。此外, 相较于 FAST-LIVO 算法, 所提算法处理每一帧数据的平均时间缩短了 17%, 计算效率更高。

4) 在长走廊模拟环境中, 与 FAST-LIVO 算法相比, 所提算法构建的地图空间结构更清晰, 线条与轮廓更精准, 噪点抑制效果更佳, 能更准确地反映真实环境布局。

#### 参考文献(References):

- [1] 吴爱祥, 王勇, 张敏哲, 等. 金属矿山地下开采关键技术新进展与展望[J]. 金属矿山, 2021(1): 1-13.  
WU Aixiang, WANG Yong, ZHANG Minzhe, et al. New development and prospect of key technology in underground mining of metal mines[J]. Metal Mine, 2021(1): 1-13.
- [2] 徐中华, 张鑫, 付信凯, 等. SLAM 技术在矿井智能化的研究现状与应用进展[J]. 安徽工业大学学报(自然科学版), 2024, 41(3): 294-304.  
XU Zhonghua, ZHANG Xin, FU Xinkai, et al. Research status and application progress of SLAM technology in mine intelligence[J]. Journal of Anhui University of Technology (Natural Science), 2024, 41(3): 294-304.
- [3] 危双丰, 庞帆, 刘振彬, 等. 基于激光雷达的同时定位与地图构建方法综述[J]. 计算机应用研究, 2020, 37(2): 327-332.  
WEI Shuangfeng, PANG Fan, LIU Zhenbin, et al. Survey of LiDAR-based SLAM algorithm[J]. Application Research of Computers, 2020, 37(2): 327-332.
- [4] 胡青松, 李敬雯, 张元生, 等. 面向矿井无人驾驶的 IMU 与激光雷达融合 SLAM 技术[J]. 工矿自动化, 2024, 50(10): 21-28.  
HU Qingsong, LI Jingwen, ZHANG Yuansheng, et al. IMU-LiDAR integrated SLAM technology for unmanned driving in mines[J]. Journal of Mine Automation, 2024, 50(10): 21-28.
- [5] 马艾强, 姚顽强. 煤矿井下移动机器人多传感器自适应融合 SLAM 方法[J]. 工矿自动化, 2024, 50(5): 107-117.  
MA Aiqiang, YAO Wanqiang. Multi sensor adaptive fusion SLAM method for underground mobile robots in coal mines[J]. Journal of Mine Automation, 2024, 50(5): 107-117.
- [6] 崔邵云, 鲍久圣, 胡德平, 等. SLAM 技术及其在矿山无人驾驶领域的研究现状与发展趋势[J]. 工矿自动化, 2024, 50(10): 38-52.  
CUI Shaoyun, BAO Jiusheng, HU Deping, et al. Research status and development trends of SLAM technology in autonomous mining field[J]. Journal of Mine Automation, 2024, 50(10): 38-52.
- [7] 高强, 陆科帆, 吉月辉, 等. 多传感器融合 SLAM 研究综述[J]. 现代雷达, 2024, 46(8): 29-39.  
GAO Qiang, LU Kefan, JI Yuehui, et al. Survey on the research of multi-sensor fusion SLAM[J]. Modern Radar, 2024, 46(8): 29-39.
- [8] SHAN Tixiao, ENGLLOT B, MEYERS D, et al. LIO-SAM: tightly-coupled lidar inertial odometry via smoothing and mapping[C]. IEEE/RSJ International Conference on Intelligent Robots and Systems, Las Vegas, 2020: 5135-5142.
- [9] XU Wei, ZHANG Fu. FAST-LIO: a fast, robust LiDAR-inertial odometry package by tightly-coupled iterated Kalman filter[J]. IEEE Robotics and Automation Letters, 2021, 6(2): 3317-3324.
- [10] ZUO Xingxing, GENEVA P, LEE W, et al. LIC-fusion: lidar-inertial-camera odometry[C]. IEEE/RSJ International Conference on Intelligent Robots and Systems, Macau, 2019: 5848-5854.
- [11] SHAN Tixiao, ENGLLOT B, RATTI C, et al. LVI-SAM: tightly-coupled lidar-visual-inertial odometry via smoothing and mapping[C]. IEEE International Conference on Robotics and Automation, Xi'an, 2021: 5692-5698.
- [12] ZHENG Chunran, ZHU Qingyan, XU We, et al. FAST-LIVO: fast and tightly-coupled sparse-direct LiDAR-inertial-visual[C]. IEEE/RSJ International Conference on Intelligent Robots and Systems, Kyoto, 2022: 4003-4009.
- [13] DAI Wei, TIAN Bailing, CHEN Hongming. Tightly-coupled lidar-inertial odometry and mapping in real time[C]. The 39th Chinese Control Conference, Shenyang, 2020: 3258-3263.
- [14] 刘宏飞, 杨耀权, 杨雨航. 基于改进光流特征的运动目标跟踪[J]. 计算机与现代化, 2021(3): 115-121.  
LIU Hongfei, YANG Yaoquan, YANG Yuhang. Moving target tracking based on improved optical flow characteristics[J]. Computer and Modernization, 2021(3): 115-121.

(下转第 166 页)



- conditions: a case study of the Wuda mining area[J/OL]. Coal Science and Technology: 1-17[2025-09-27]. <https://kns.cnki.net/KCMS/detail/detail.aspx?filename=MTKJ20250903002&dbname=CJFD&dbcode=CJFQ>.
- [20] 鞠金峰, 许家林, 刘阳军, 等. 关键层运动监测及岩移 5 阶段规律——以红庆河煤矿为例[J]. 煤炭学报, 2022, 47(2): 611-622.
- JU Jinfeng, XU Jialin, LIU Yangjun, et al. Key strata movement monitoring during underground coal mining and its 5-stage movement law inversion: a case study in Hongqinghe Mine[J]. Journal of China Coal Society, 2022, 47(2): 611-622.
- [21] 李一哲, 张闯, 郝晓波, 等. 基于地表沉陷参数的工作面合理回采速度: 以内蒙古红庆梁煤矿为例[J]. 科学技术与工程, 2025, 25(25): 10612-10618.
- LI Yizhe, ZHANG Chuang, HAO Xiaobo, et al. Reasonable mining speed of working face based on surface subsidence parameters: Hongqingliang Coal Mine in Inner Mongolia[J]. Science Technology and Engineering, 2025, 25(25): 10612-10618.
- [22] 郭文兵, 李圣军. “三软”特厚煤层开采地表沉陷规律研究[J]. 河南理工大学学报(自然科学版), 2014, 33(6): 733-737.
- GUO Wenbing, LI Shengjun. Study pattern of surface subsidence characteristics of "three-soft" and especially thick coal seam mining[J]. Journal of Henan Polytechnic University (Natural Science), 2014, 33(6): 733-737.
- [23] 张海君, 吴奕枢, 王飞, 等. 准格尔煤田龙王沟煤矿特厚煤层综放开采地表沉陷规律[J]. 西安科技大学学报, 2022, 42(5): 874-883.
- ZHANG Haijun, WU Yishu, WANG Fei, et al. Surface subsidence law in fully-mechanized caving mining of extra-thick seam in Longwanggou Coal Mine of Zhungeer coalfield[J]. Journal of Xi'an University of Science and Technology, 2022, 42(5): 874-883.
- [24] 彭宝山, 王永乐, 杨学孟. 特厚弱胶结顶板煤层综放开采覆岩破坏特征与强矿压机理[J]. 煤炭技术, 2024, 43(10): 75-80.
- PENG Baoshan, WANG Yongle, YANG Xuemeng. Overburden rock failure characteristics and strong mine pressure mechanism of fully-mechanized caving mining in extra-thick and weakly cemented roof coal seam[J]. Coal Technology, 2024, 43(10): 75-80.
- [25] 赵志宁, 潘卫东, 邓藏. 基于推进速度效应的坚硬顶板大采高工作面煤壁稳定性控制研究[J/OL]. 煤炭科学技术: 1-17[2025-07-14]. <https://kns.cnki.net/KCMS/detail/detail.aspx?filename=MTKJ20250625008&dbname=CJFD&dbcode=CJFQ>.
- ZHAO Zhining, PAN Weidong, DENG Cang. Stability control of coal wall in ultra-large-mining-height working face with hard roof based on advance speed effect[J/OL]. Coal Science and Technology: 1-17[2025-07-14]. <https://kns.cnki.net/KCMS/detail/detail.aspx?filename=MTKJ20250625008&dbname=CJFD&dbcode=CJFQ>.
- (上接第 149 页)
- [15] SIONG L Y, MOKRI S S, HUSSAIN A, et al. Motion detection using Lucas Kanade algorithm and application enhancement[C]. International Conference on Electrical Engineering and Informatics, Bangi, 2009: 537-542.
- [16] BELL B M, CATHEY F W. The iterated Kalman filter update as a Gauss-Newton method[J]. IEEE Transactions on Automatic Control, 1993, 38(2): 294-297.
- [17] XU Wei, CAI Yixi, HE Dongjiao, et al. FAST-LIO2: fast direct LiDAR-inertial odometry[J]. IEEE Transactions on Robotics, 2022, 38(4): 2053-2073.
- [18] 黄远征, 尹春丽, 刘波, 等. 基于改进的快速 Shi-Tomasi 特征点检测算法的图像拼接算法[J]. 机械设计与研究, 2018, 34(4): 70-73.
- HUANG Yuanzheng, YIN Chunli, LIU Bo, et al. Image mosaic algorithm based on improved fast Shi-tomasi feature points detection algorithm[J]. Machine Design & Research, 2018, 34(4): 70-73.
- [19] YIN Jie, LI Ang, LI Tao, et al. M2DGR: a multi-sensor and multi-scenario SLAM dataset for ground robots[J]. IEEE Robotics and Automation Letters, 2022, 7(2): 2266-2273.
- [20] SHAN Tixiao, ENGLLOT B. LeGO-LOAM: lightweight and ground-optimized lidar odometry and mapping on variable terrain[C]. IEEE/RSJ International Conference on Intelligent Robots and Systems, Madrid, 2018: 4758-4765.
- [21] YUAN Chongjian, LIU Xiyuan, HONG Xiaoping, et al. Pixel-level extrinsic self calibration of high resolution LiDAR and camera in targetless environments[J]. IEEE Robotics and Automation Letters, 2021, 6(4): 7517-7524.